



## **DADOS MAPEAMENTO ÁREA DE PASTAGEM PARA O BRASIL**

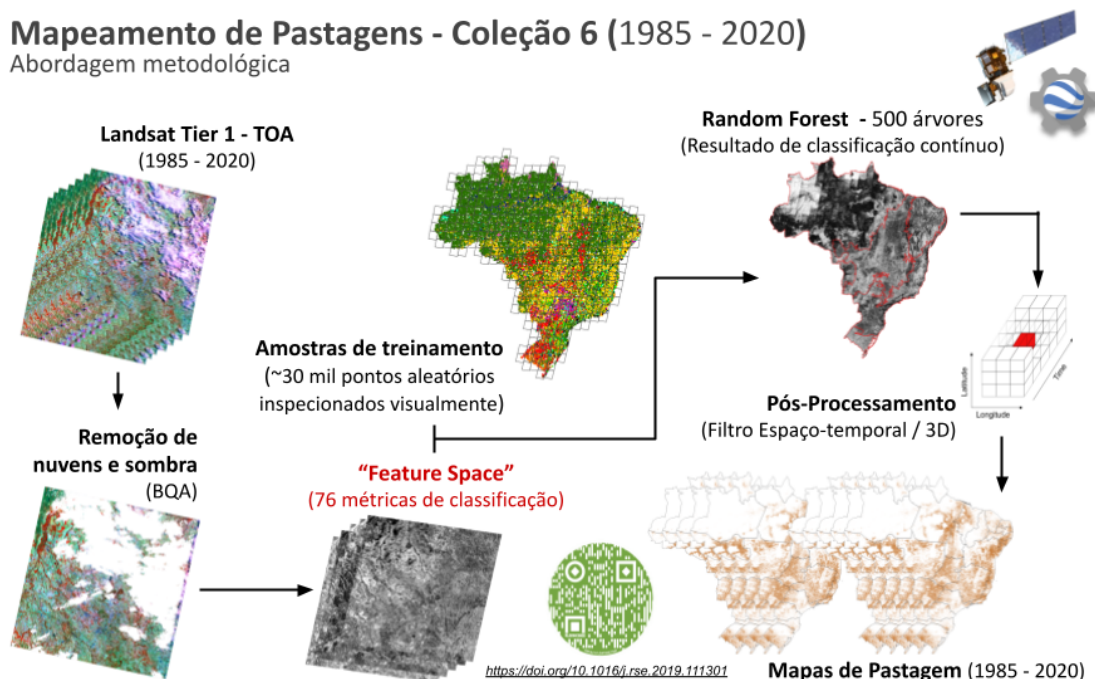
Documento produzido pela equipe do Núcleo de Pesquisa em Pastagem do Laboratório de Processamento de Imagens e Geoprocessamento (Lapig), da Universidade Federal de Goiás (UFG), coordenado pelo professor Laerte Guimarães Ferreira. Este e outros métodos dos dados referentes às pastagens brasileiras estão disponíveis na plataforma [Atlas das Pastagens](#).

Goiânia, janeiro de 2022.

## 1. Visão geral

No contexto das informações produzidas no âmbito da iniciativa MapBiomass (mapbiomas.org), encontram-se mapas que descrevem a dinâmica de ocupação do solo brasileiro por pastagens nos últimos 36 anos (Coleção 6).


Este mapeamento de pastagens foi baseado na abordagem descrita em Parente *et al.* (2017, 2019) usando imagens da série de satélites Landsat e o classificador supervisionado Random Forest (Breiman, 2001), bem como um amplo feature space (Pasquarella *et al.*, 2018) e robustas técnicas estatística de amostragem (para fins de calibração e validação dos modelos de classificação) (figura 1).



**Figura 1.** Fluxograma representando as etapas de produção do mapeamento de pastagens para o Brasil.

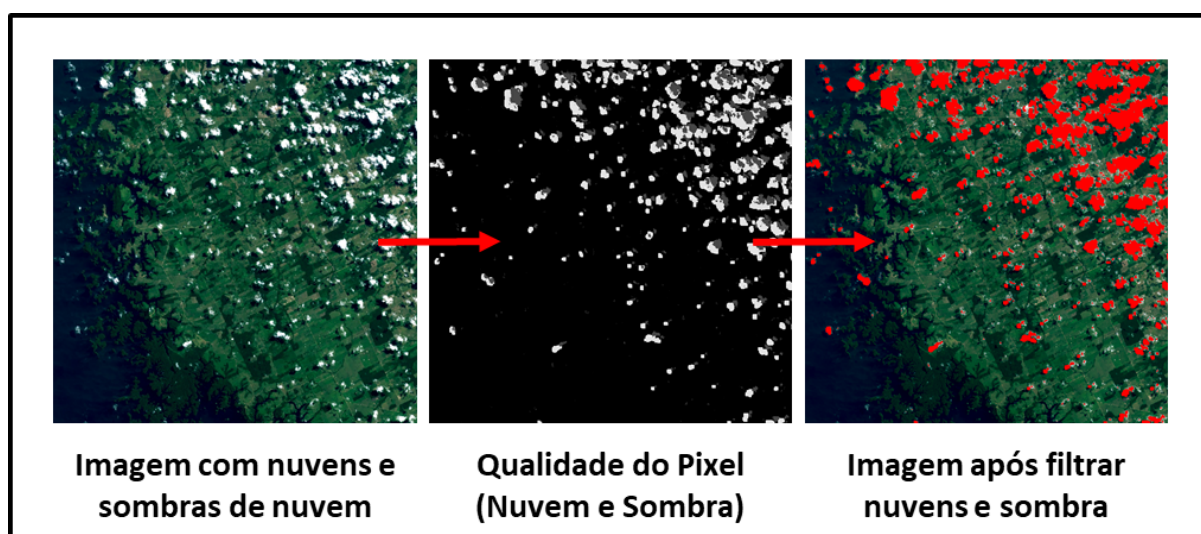
## 2. Abordagem de mapeamento

Nossa abordagem de mapeamento considerou como unidade de classificação os limites úteis das cenas Landsat (de acordo com o Sistema de Referência Mundial - WRS-2 Órbita / Linha sem as zonas de sobreposição - figura 2) e uma janela de tempo de 24 meses, para todo o país, garantindo a prevalência de observações de um ano específico (e.g. o *feature space* de 2015 considerou imagens do segundo semestre de 2014 até o primeiro semestre de 2016). Essa janela de tempo proporcionou séries temporais mais densas para a geração do *feature space*, que foi capaz de captar, de forma mais adequada às variações do vigor vegetativo das pastagens, uma vez que essas áreas são muito suscetíveis às variações climáticas (Ferreira *et al.*, 2013).



**Figura 2.** Cenas Landsat (WRS) consideradas para o mapeamento das áreas de pastagens entre os anos de 1985 a 2020.

O mapeamento da pastagem foi produzido com dados Landsat Collection 1 Tier 1, adquiridos entre 1985 e 2020 (Markham & Helder, 2012). As imagens Landsat 5 foram usadas na primeira metade da série temporal (ou seja, de 1985 a 1999). As imagens adquiridas pelo Landsat 7 foram consideradas apenas para 2000, 2001, 2002 e 2012. Para os períodos de tempo de 2003 a 2011 e de 2013 a 2020 usamos, respectivamente, imagens Landsat 5 e Landsat 8. Essas séries temporais foram normalizadas para refletâncias do topo da atmosfera (TOA) e selecionadas conforme a banda de avaliação de qualidade Landsat (BQA = 2720 para Landsat 8 e BQA = 672 para Landsat 5/7) a fim de remover pixels contaminados com nuvens e sombras de nuvens, como apresentado (figura 3).



**Figura 3.** Exemplificação do processo de remoção, pixel a pixel, de ruídos de nuvem e sombra de cada imagem utilizada.

Com imagens Landsat filtradas com BQA e selecionadas de acordo com a janela de tempo estabelecida (24 meses), cinco operações foram aplicadas (*i.e.* média, desvio padrão, mínimo, máximo, amplitude e percentis) em seis bandas espectrais (*i.e.*, verde, vermelho, infravermelho próximo, infravermelho de ondas

curtas 1 e infravermelho de ondas curtas 2) e três índices espectrais (*i.e.* Índice de Vegetação de Diferença Normalizada - NDVI, Índice de Água de Diferença Normalizada - NDWI (Gao, 1996) e o Índice de Absorção de Celulose - CAI (Nagler *et al.*, 2003). Também foram consideradas informações de elevação e declividade, derivadas de um Modelo Digital de Elevação (DEM), e coordenadas geográficas. No total, nosso mapeamento de pastagem utilizou 72 bandas espectro-temporais e quatro métricas espaciais (tabela 1).

**Tabela 1.** *Feature space* utilizado na classificação da pastagem (MapBiomass Coleção 6), com um total de 72 métricas espectral-temporais e quatro métricas espaciais.

#	Bandas/Índices	Operação	Período	Coleção
1	Verde	Média	WET	3, 4, 5 e 6
2	Verde	Desvio Padrão	WET	3, 4, 5 e 6
3	Verde	Mínimo	WET	3, 4, 5 e 6
4	Verde	Máximo	WET	3, 4, 5 e 6
5	Verde	Amplitude	WET	3, 4, 5 e 6
6	Verde	Percentil 10%	WET	5 e 6
7	Verde	Percentil 25%	WET	5 e 6
8	Verde	Percentil 75%	WET	5 e 6
9	Verde	Percentil 90%	WET	5 e 6
10	Vermelho	Média	WET	3, 4, 5 e 6
11	Vermelho	Desvio Padrão	WET	3, 4, 5 e 6
12	Vermelho	Mínimo	WET	3, 4, 5 e 6
13	Vermelho	Máximo	WET	3, 4, 5 e 6
14	Vermelho	Amplitude	WET	3, 4, 5 e 6


15	Vermelho	Percentil 10%	WET	5 e 6
16	Vermelho	Percentil 25%	WET	5 e 6
17	Vermelho	Percentil 75%	WET	5 e 6
18	Vermelho	Percentil 90%	WET	5 e 6
	Infravermelho			
19	Próximo	Média	WET	3, 4, 5 e 6
	Infravermelho			
20	Próximo	Desvio Padrão	WET	3, 4, 5 e 6
	Infravermelho			
21	Próximo	Mínimo	WET	3, 4, 5 e 6
	Infravermelho			
22	Próximo	Máximo	WET	3, 4, 5 e 6
	Infravermelho			
23	Próximo	Amplitude	WET	3, 4, 5 e 6
	Infravermelho			
24	Próximo	Percentil 10%	WET	5 e 6
	Infravermelho			
25	Próximo	Percentil 25%	WET	5 e 6
	Infravermelho			
26	Próximo	Percentil 75%	WET	5 e 6
	Infravermelho			
27	Próximo	Percentil 90%	WET	5 e 6
28	SWIR1	Média	WET	3, 4, 5 e 6
29	SWIR1	Desvio Padrão	WET	3, 4, 5 e 6
30	SWIR1	Mínimo	WET	3, 4, 5 e 6
31	SWIR1	Máximo	WET	3, 4, 5 e 6
32	SWIR1	Amplitude	WET	3, 4, 5 e 6
33	SWIR1	Percentil 10%	WET	5 e 6
34	SWIR1	Percentil 25%	WET	5 e 6

35	SWIR1	Percentil 75%	WET	5 e 6
36	SWIR1	Percentil 90%	WET	5 e 6
37	SWIR2	Média	WET	3, 4, 5 e 6
38	SWIR2	Desvio Padrão	WET	3, 4, 5 e 6
39	SWIR2	Mínimo	WET	3, 4, 5 e 6
40	SWIR2	Máximo	WET	3, 4, 5 e 6
41	SWIR2	Amplitude	WET	3, 4, 5 e 6
42	SWIR2	Percentil 10%	WET	5 e 6
43	SWIR2	Percentil 25%	WET	5 e 6
44	SWIR2	Percentil 75%	WET	5 e 6
45	SWIR2	Percentil 90%	WET	5 e 6
46	NDVI	Média	WET	3, 4, 5 e 6
47	NDVI	Desvio Padrão	WET	3, 4, 5 e 6
48	NDVI	Mínimo	WET	3, 4, 5 e 6
49	NDVI	Máximo	WET	3, 4, 5 e 6
50	NDVI	Amplitude	WET	3, 4, 5 e 6
51	NDVI	Percentil 10%	WET	5 e 6
52	NDVI	Percentil 25%	WET	5 e 6
53	NDVI	Percentil 75%	WET	5 e 6
54	NDVI	Percentil 90%	WET	5 e 6
55	NDWI (Gao, 1996)	Média	WET	3, 4, 5 e 6
56	NDWI (Gao, 1996)	Desvio Padrão	WET	3, 4, 5 e 6
57	NDWI (Gao, 1996)	Mínimo	WET	3, 4, 5 e 6
58	NDWI (Gao, 1996)	Máximo	WET	3, 4, 5 e 6
59	NDWI (Gao, 1996)	Amplitude	WET	3, 4, 5 e 6
60	NDWI (Gao, 1996)	Percentil 10%	WET	5 e 6

61	NDWI (Gao, 1996)	Percentil 25%	WET	5 e 6
62	NDWI (Gao, 1996)	Percentil 75%	WET	5 e 6
63	NDWI (Gao, 1996)	Percentil 90%	WET	5 e 6
64	CAI (Nagler <i>et al.</i> , 2003)	Média	WET	3, 4, 5 e 6
65	CAI (Nagler <i>et al.</i> , 2003)	Desvio Padrão	WET	3, 4, 5 e 6
66	CAI (Nagler <i>et al.</i> , 2003)	Mínimo	WET	3, 4, 5 e 6
67	CAI (Nagler <i>et al.</i> , 2003)	Máximo	WET	3, 4, 5 e 6
68	CAI (Nagler <i>et al.</i> , 2003)	Amplitude	WET	3, 4, 5 e 6
69	CAI (Nagler <i>et al.</i> , 2003)	Percentil 10%	WET	5 e 6
70	CAI (Nagler <i>et al.</i> , 2003)	Percentil 25%	WET	5 e 6
71	CAI (Nagler <i>et al.</i> , 2003)	Percentil 75%	WET	5 e 6
72	CAI (Nagler <i>et al.</i> , 2003)	Percentil 90%	WET	5 e 6
73	SRTM (Farr <i>et al.</i> , 2007)	Elevation	-	5 e 6
74	SRTM (Farr <i>et al.</i> , 2007)	Slope	-	5 e 6
75	Geographic Coordinate	Latitude	-	5 e 6
76	Geographic Coordinate	Longitude	-	5 e 6



Todas as cenas classificadas foram mosaicadas por ano, produzindo assim uma série temporal de mapas de probabilidade de pastagem. Para aprimorar esses resultados, aplicamos um filtro espaço-tempo, capaz de minimizar transições abruptas, e às vezes irreais, utilizando simultaneamente informações dessas duas dimensões. O filtro, implementado por meio da biblioteca SciPy (Scipy, 2018), utilizou uma janela de tempo de 5 anos e 3 x 3 pixels para substituir o valor do kernel central pela mediana de 45 valores de probabilidade (figura 4). Sobre este resultado, foi aplicado um limite de 51% (Parente *et al.*, 2019), para produzir os mapas de pastagem para o Brasil.



**Figura 4.** Ilustração da técnica de filtragem multidimensional utilizada no mapeamento das pastagens. É realizada uma filtragem no espaço (3x3 pixels) e no tempo (5 anos) com o uso de um kernel 3D de 3x3x5.

Realizamos uma avaliação de qualidade independente considerando 5.000 pontos de validação. O desenho amostral de validação também considerou um



mapa de pastagem de 2015 (Parente *et al.*, 2017), de forma que o número de pontos aleatórios pudesse ser balanceado por classe (ou seja, 2.500 para a classe "pastagem" e 2.500 para a "não pastagem" ), assumindo conservadoramente que a precisão mínima do mapeamento foi de 50% e o erro de avaliação da precisão foi de 1% dentro de um intervalo de confiança de 95% (Lohr, 2009).

As amostras de validação foram inspecionadas por cinco intérpretes, mas apenas pontos com concordância de quatro ou mais votos foram considerados na avaliação de acurácia (ou seja, pelo menos quatro intérpretes identificaram a mesma cobertura da terra e classe de uso da terra), resultando em (pelo menos) 4.100 amostras disponível para cada ano. Para todos os mapas de pastagem, a acurácia global, do produtor e do usuário foram avaliadas com uma matriz de confusão balanceada, a qual remove o viés de amostragem (Pontius & Millones, 2011).

O mapeamento da pastagem apresentou uma precisão geral de ~ 91%, uma precisão do usuário de ~ 95% (de 2000 em diante) e uma precisão do produtor variando entre 60% e 72%, indicando uma prevalência de erros de omissão em todos os anos.

## Referências

BREIMAN, L. Random forests. Machine learning, v. 45, n. 1, p. 5-32, 2001.

FARR, T. G., et al. (2007), The Shuttle Radar Topography Mission, Rev. Geophys., V45

GAO, B.C. NDWI – A Normalized Difference Water Index for remote sensing of vegetation liquid water from space. Remote Sensing of Environment, v.58, p.257-266, 1996.



LOHR, S.L. Sampling: Design and Analysis, 2 edition. ed. Cengage Learning, Boston, Mass, 2009.

MARKHAM, B. L.; STOREY, J. C.; WILLIAMS, D. L.; IRONS, J. R. Landsat sensor performance: history and current status. Geoscience and Remote Sensing, IEEE Transactions on, v. 42, n. 12, p. 2691-2694, 2004.

MARKHAM, B. L.; HELDER, D. L. Forty-year calibrated record of earth-reflected radiance from Landsat: A review. Remote Sensing of Environment, v. 122, p. 30-40, 2012.

NAGLER, P. L.; INOUE, Y.; CLENN, E. P.; RUSS, A. L.; DAUGHTRY, C. S. T. Cellulose absorption index (CAI) to quantify mixed soil-plant litter scenes. Remote Sens Environ, v. 87, pp. 310–325, 2003.

PARENTE, L.; FERREIRA, L.; FARIA, A.; NOGUEIRA, S.; ARAÚJO, F.; TEIXEIRA, L.; HAGEN, S. Monitoring the brazilian pasturelands: A new mapping approach based on the landsat 8 spectral and temporal domains. International Journal of Applied Earth Observation and Geoinformation, v. 62, p. 135-143, 2017.

PARENTE, L.; FERREIRA, L.. Assessing the Spatial and Occupation Dynamics of the Brazilian Pasturelands Based on the Automated Classification of MODIS Images from 2000 to 2016. Remote Sensing, v. 10, n. 4, p. 606, 2018.

PARENTE, L.; MESQUITA, V.; MIZIARA, F.; BAUMANN, L.; FERREIRA, L. Assessing the pasturelands and livestock dynamics in Brazil, from 1985 to 2017: A novel approach based on high spatial resolution imagery and Google Earth Engine cloud computing. Remote Sens. Environ. 2019, 232, 111301.

PASQUARELLA, V. J.; HOLDEN, C. E.; WOODCOCK, C. E. Improved mapping of forest type using spectral-temporal Landsat features. Remote Sensing of Environment, v. 210, p. 193-207, 2018.

PONTIUS JR, R. G.; & MILLONES, M. Death to Kappa: birth of quantity disagreement and allocation disagreement for accuracy assessment. International Journal of Remote Sensing, v. 32, n. 15, p. 4407-4429, 2011.



SCIPY. Reference Guide - SciPy v1.1.0. Available online: <https://docs.scipy.org/doc/scipy-1.1.0/reference/generated/scipy.ndimage.median.html> (accessed on 01 August 2018).

WANG, J.; ZHAO, Y.; LI, C.; YU, L.; LIU, D.; GONG, P. Mapping global land cover in 2001 and 2010 with spatial-temporal consistency at 250 m resolution. ISPRS Journal of Photogrammetry and Remote Sensing, v. 103, p. 38-47, 2015.